这次实验做出了什么

我们完成了一个“英文或中文影像报告输入，中文解释输出”的研究原型，并在学校的A100上真正训练了一个LoRA适配器。固定测试集上的文字相似度有所提升，但实际输出仍有数字、否定范围和确定性错误。这个项目适合学习模型微调与评估，目前不适合直接给患者作为可靠解释使用。

这是放射科报告通俗化，不是根据影像诊断，也不是把各种处方和医嘱自动改写成用药指导。原课程文件的放射科报告选题是起点；我们为中文目标选择Qwen，作为独立兴趣项目，不提交为第二份课程作业。

真实运行的规模和耗时

项目	实测值
学校GPU	NVIDIA A100-PCIE-40GB
原始抽样训练记录	4,096
通过格式检查并实际训练	4,066
实际开发集训练损失评估记录	250
最终测试输入	256
有可用合成中文参考、参与文字评分	249
教师生成中文参考	19.9分钟
两轮LoRA训练	9.4分钟
主GPU作业总时长，含下载和评估	47分52秒
合并导出作业	2分12秒
可训练参数	4,358,144，约占总参数0.28%
训练峰值已分配显存	10.10GiB
训练峰值预留显存	32.16GiB

总时长不是从写代码到完整交付的时间，也不包括Mac下载、量化与验证。实际训练很快，数据处理、参考质量、错误分析和本地运行验证占了更多工作。

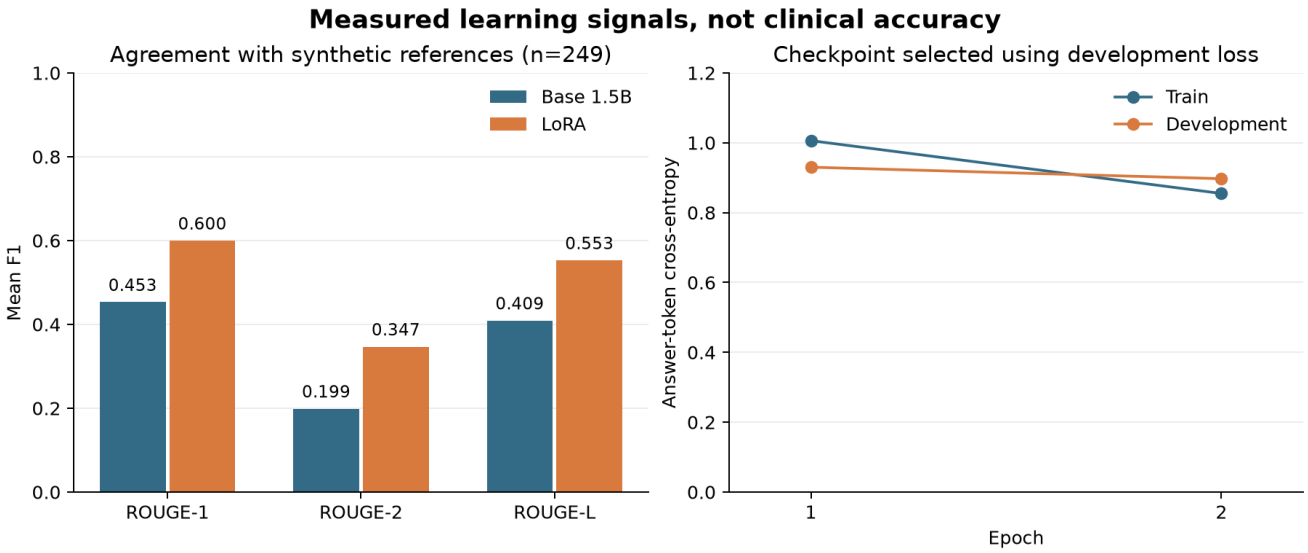
开发集回答损失从第1轮的0.930降到第2轮的0.897，因此选择第2轮。这个选择发生在读取最终测试指标之前。训练时只更新LoRA参数；基础模型和教师模型的原始权重没有参与这次梯度更新。

分数说明了什么

指标	未微调基线	LoRA微调
ROUGE-1	0.453	0.600
ROUGE-2	0.199	0.347
ROUGE-L	0.409	0.553
chrF，0到100	26.887	37.335
中文字符比例达到设定阈值的输出	97.66%	100%
正常生成结束	100%	100%
A100批量生成吞吐，token/秒	144.6	96.8

ROUGE-L的配对平均差为+0.1437，2,000次配对bootstrap得到的95%百分位区间为[+0.1263, +0.1610]。这只是当前249条报告及合成参考条件下的文字指标区间，不能解释成医学正确率或患者级独立验证。

分数提升说明学生更接近教师的措辞。中文参考由同一模型家族的7B模型生成，没有医生逐条验证。微调版在这里的未合并LoRA推理更慢；本地合并量化后的速度需要另外测量，不能从这组批量吞吐推断。



两个改善和三个失败

以下都是预先编写的合成挑战输入产生的真实输出，没有为展示效果重新生成或挑选随机种子。全部20条对比在 results/pilot_v1/challenge_review.json。

改善：保留“性质未定”。 输入描述右肺上叶6毫米结节，性质未定，建议与既往影像比较。基线没有写出性质未定；LoRA明确写出“目前不确定其性质”。

改善：不再混淆积液与积气。 输入左侧少量胸腔积液、右侧没有积液。基线写“积液（积气）”；LoRA去除了错误的积气括注，保留了左右差异。

失败：新增错误的算术。 输入从5毫米变成8毫米、3个月后复查CT。LoRA原样输出：

左下肺有一个小结节，现在比之前大了1毫米，从5毫米变成了8毫米。建议三个月后复查CT。

两个原始数字都出现了，但新增的增量是错的。仅检查是否包含5和8不能发现所有问题。

失败：中文输入也会改错数字。 输入约7毫米、之前6毫米、6个月后复查。基线保留了两个大小；LoRA写“比之前大了0.5毫米”。训练主要覆盖英文到中文，不能因为基础模型支持中文，就认为中文输入已经充分验证。

失败：扩大否定范围。 输入“未见明显实变影”，LoRA写“双肺看起来正常”。原文只否定某类发现，模型却扩大成了整体正常。数字检查器无法发现这种语义变化。

真实数据中的五类观察

这五例按原报告的关键词选择，不按哪个模型表现更好来选择。完整原文与输出仅保存在本地 results/pilot_v1/case-review.json；Git仓库保留ID及分析。以下是AI辅助的文字核对，没有医生审核。

1. **否定及源文歧义。** 某原文把未见肺动脉充盈缺损与支持肺栓塞的措辞放在同一句。两个模型都没有明确指出冲突；教师参考也有解剖名词误写。这例不应被当作没有争议的标准答案。

2. **不确定性与日期。** 两模型保留了炎症或感染的可能性，但教师和学生对模糊日月格式的理解不同。参考不一定永远正确；单凭文字不一致无法判定哪一个日期解释正确。

3. **随访间隔。** 一份长报告建议6个月后复查，LoRA改成3个月，并遗漏结节大小；基线保留间隔，却误译了其他发现。更高的总分掩盖不了这类改变。

4. **不能排除变成确定。** 一例原文说不能排除某区域病变，LoRA改成仍然存在病理变化。基线在这一点上更忠实。

5. **导管和解剖部位。** LoRA更清楚保留了导管尖端位置及肺门描述，但仍有未解释术语和细节省略，不能认为通俗化已经完成。

本地程序额外做了什么

在看到上述数字错误之后，增加了一个独立的数字与单位核对器。它对比原文和生成文本中的毫米、厘米、常见随访时间，可以识别30毫米等于3厘米、半年等于6个月，并提示新增或遗漏的数值。

它**不会改写模型答案**，也没有参与训练、选模或以上原始指标计算。这是试验之后增加的应用层提示，不能作为模型在盲测中通过的能力。数值相同但前后顺序颠倒、否定改变、左右侧错误、复杂范围和其他医学事实，都可能漏检。没有提示也不代表答案正确。

Mac的4位模型已完成单独验证。权重文件868,629,082字节，约869MB；20条短报告全部正常结束，总生成时间13.19秒，单条中位数0.62秒。MLX记录的峰值分配内存1.12GiB，这不是进程总内存或Mac整体内存占用。时间统计不含模型加载，包含首次生成编译，不代表长报告也能在相同时间完成。

20条中有19条文本与A100的LoRA输出不同。这里同时发生了适配器合并、4位量化、推理框架和批处理方式变化，不能把所有差异单独归因于量化。某个数字错误消失了，但另一些例子出现新错误：导管位置的“气管分叉上方”变成“距离气管环”，改善方向也出现表达混淆。完整三版本对比保存在 results/pilot_v1/challenge_review.json。

已实际运行中文文件输入、JSON输出、数字遗漏提示和交互启动脚本。例如输入“左侧少量胸腔积液，右侧未见积液。心影不大。”，本地输出“左侧胸腔有少量积液，右侧没有。心脏大小正常。”。这个例子也显示，模型仍未把每一个专业词解释成日常语言。

在你的Mac上使用

项目位于 /Users/jiangfu/Downloads/3710/radiology-plain-zh。双击其中的 开始解释报告.command，粘贴英文或中文报告，再输入一个空行；输入q退出。模型和环境都保存在这个独立目录，日常推理不需要学校GPU，这些推理脚本不会把报告文本发送给外部服务。

模型权重及原始数据没有放进GitHub，代码、配置、测量结果、完整合成挑战对比和中文说明已经提交。独立克隆仓库需要重新运行训练/导出流程获得权重。本机和学校项目目录中的权重保留了上游模型许可及修改说明。

用这个项目学会六件事

1. **基线很重要。** 原始Qwen已经会说中文。只有同样输入、提示词和生成设置的前后对比，才能看出微调改变了什么。

2. **LoRA只训练一小部分。** 大约15亿参数的语言能力来自预训练；这次训练约436万参数，使它更适应报告解释风格。

3. **合成标签便宜但会带错。** 教师可以快速生成数千条中文参考，同时也会产生误译和难懂术语。学生可能忠实地学到这些问题。

4. **损失下降是学习信号，不是临床认证。** 模型更会预测参考答案中的词，不代表每一个数值和判断都保真。

5. **测试必须看内容。** 文字指标、事实核对和患者可读性是不同的问题，需要分别评估。

6. **部署是另一段实验。** GPU上跑通之后，还要做权重合并、压缩、下载、校验以及本地实际生成。

如果继续做下一轮，最有价值的方向是人工审核的中文成对数据、数字与否定等细粒度训练样例、独立的中文测试集，以及专业人员的事实与可读性评估。不能在看过这次测试输出之后反复调参，再把同一批报告称作新的盲测。

证据与复现

主实验运行源码为 d081044，后续版本增加本地界面、复现参数、数值提示和分析。results/pilot_v1/comparison.json包含训练历史、固定划分、教师统计和指标；models.lock.json记录模型revision；paired_lexical_analysis.json记录bootstrap设置。

原配置中的 max_source_tokens=640 没有在该版代码中使用。实际约束为报告及英文参考各20到2,400字符、训练完整序列不超过1,152token；没有因完整训练序列过长而剔除样本。这个未使用字段不应被误读成已经执行的640token截断。

来源：BioLaySumm LaymanRRG、Qwen2.5-1.5B-Instruct、Qwen2.5-7B-Instruct、PEFT LoRA、MLX LM。